

2026.03.10 電子情報通信総合大会

ゼロショット分類に特化した 表現分離に基づく共通空間学習

大阪工業大学 ロボティクス&デザイン工学部 システムデザイン工学科


高橋 清彌, 瀬尾 昌孝

アウトライン

1. 研究背景・目的
2. 関連研究
 - 2.1. CLIP, CLAP
 - 2.2. 共通-固有分離
3. ゼロショット分類に特化した共通空間
 - 3.1. 類似度計算に固有表現はノイズ
 - 3.2. InfoNCEは固有表現を抑制できない
4. モデル構造と学習方法
5. 実験
6. 結論


1. 研究背景・目的

一般的な多クラス分類のモデル



1. 研究背景・目的


一般的な多クラス分類は未知のクラスに対応出来ない



1. 研究背景・目的

ゼロショット分類とは

一般的な多クラス分類




未知のクラスに再学習必要

1. 研究背景・目的


ゼロショット分類とは

一般的な多クラス分類



未知のクラスに再学習必要

ゼロショット分類




画像表現とクラス言語表現間の類似度

1. 研究背景・目的


ゼロショット分類とは

一般的な多クラス分類



未知のクラスに再学習必要



ゼロショット分類



画像表現とクラス言語表現間の類似度
未知のクラスに再学習が不要


1. 研究背景・目的

類似度計算を行うには、表現間で**軸整合**が行われている必要がある



1. 研究背景・目的

類似度計算を行うには、表現間で**軸整合**が行われている必要がある




1. 研究背景・目的

現状：類似度計算を不要な情報も用いている

1. 研究背景・目的

現状：類似度計算に不要な情報も用いている


目的：類似度計算を共通表現（必要な情報）のみで行う



CLIP, CLAP → 一般的な共通-固有分離

2. 関連研究


共通空間を作る代表的な手法：CLIP



CLIP, CLAP → 一般的な共通-固有分離

2. 関連研究


共通空間を作る代表的な手法：CLIP



CLIP, CLAP → 一般的な共通-固有分離

2. 関連研究

共通空間を作る代表的な手法：CLIP




対応するデータの類似度を高く
対応しないデータの類似度を低く
InfoNCE損失を最小化

CLIP, CLAP → 一般的な共通-固有分離

2. 関連研究

共通空間を作る代表的な手法：CLIP



対応するデータの類似度を高く
対応しないデータの類似度を低く
InfoNCE損失を最小化


$$-\frac{1}{B} \sum_{i=1}^B \log \frac{\exp(\text{正例類似度})}{\sum \exp(\text{負例類似度})}$$

正例：対応するデータ
負例：対応しないデータ

CLIP, CLAP → 一般的な共通-固有分離

2. 関連研究

共通空間を作る代表的な手法：CLIP



対応するデータの類似度を高く
対応しないデータの類似度を低く
InfoNCE損失を最小化

$$-\frac{1}{B} \sum_{i=1}^B \log \frac{\exp(\text{正例類似度})}{\sum \exp(\text{負例類似度})}$$

正例：対応するデータ
負例：対応しないデータ

言語と音声に拡張したCLAP



CLIP, CLAP → 一般的な共通-固有分離

2. 関連研究

モダリティ間の共通表現と固有表現の概念

意味
感情
語彙
視点
丁寧
言語表現




速さ
声質
感情
抑揚
意味
音声表現

CLIP, CLAP → 一般的な共通-固有分離

2. 関連研究

一般的な共通-固有分離手法



アウトライン

1. 研究背景・目的
2. 関連研究
 - 2.1. CLIP, CLAP
 - 2.2. 共通-固有分離
3. ゼロショット分類に特化した共通空間
 - 3.1. 類似度計算に固有表現はノイズ
 - 3.2. InfoNCEは固有表現を抑制できない
4. モデル構造と学習方法
5. 実験
6. 結論

前提 → 類似度計算に固有表現はノイズ → InfoNCEは固有表現を抑制できない

3. ZS分類に特化した共通空間

3章における前提条件

潜在表現は、**共通**-固有表現に分けることが出来る

$$z_{m1} = \mathbf{c}_{m1} + p_{m1}, z_{m2} = \mathbf{c}_{m2} + p_{m2}$$

c_{m1}, c_{m2} は、**軸整合**は行われていない

意味
感情
語彙
視点
丁寧

速さ
声質
感情
抑揚
意味

前提 → 類似度計算に固有表現はノイズ → InfoNCEは固有表現を抑制できない

3. ZS分類に特化した共通空間

3章における前提条件

潜在表現は、**共通**-固有表現に分けることが出来る

$$z_{m1} = \mathbf{c}_{m1} + p_{m1}, z_{m2} = \mathbf{c}_{m2} + p_{m2}$$

c_{m1}, c_{m2} は、**軸整合**は行われていない

CLIP同様の線形変換 M_{m1}, M_{m2} を導入

$$h_{m1} = M_{m1}(\mathbf{c}_{m1} + p_{m1}) = \mathbf{c} + p'_{m1}$$

$$h_{m2} = M_{m2}(\mathbf{c}_{m2} + p_{m2}) = \mathbf{c} + p'_{m2}$$

軸整合が行われ、 c_{m1}, c_{m2} は c となる

前提 → 類似度計算に固有表現はノイズ → InfoNCEは固有表現を抑制できない

3. ZS分類に特化した共通空間

h_{m1} , h_{m2} 間の類似度計算

$$h_{m1} = M_{m1}(c_{m1} + p_{m1}) = \mathbf{c} + \mathbf{p}'_{m1}$$

$$h_{m2} = M_{m2}(c_{m2} + p_{m2}) = \mathbf{c} + \mathbf{p}'_{m2}$$

前提 → 類似度計算に固有表現はノイズ → InfoNCEは固有表現を抑制できない

3. ZS分類に特化した共通空間

h_{m1}, h_{m2} 間の類似度計算

$$h_{m1} = M_{m1}(c_{m1} + p_{m1}) = \mathbf{c} + \mathbf{p}'_{m1}$$

$$h_{m2} = M_{m2}(c_{m2} + p_{m2}) = \mathbf{c} + \mathbf{p}'_{m2}$$

h_{m1}, h_{m2} に対して、類似度計算を行う

$$\text{sim}(h_{m1}, h_{m2}) = \frac{\langle \mathbf{c} + \mathbf{p}'_{m1}, \mathbf{c} + \mathbf{p}'_{m2} \rangle}{\|h_{m1}\| \|h_{m2}\|}$$

前提 → 類似度計算に固有表現はノイズ → InfoNCEは固有表現を抑制できない

3. ZS分類に特化した共通空間

h_{m1}, h_{m2} 間の類似度計算

$$h_{m1} = M_{m1}(c_{m1} + p_{m1}) = \mathbf{c} + \mathbf{p}'_{m1}$$

$$h_{m2} = M_{m2}(c_{m2} + p_{m2}) = \mathbf{c} + \mathbf{p}'_{m2}$$

h_{m1}, h_{m2} に対して、**類似度計算**を行う

$$\text{sim}(h_{m1}, h_{m2}) = \frac{\langle \mathbf{c} + \mathbf{p}'_{m1}, \mathbf{c} + \mathbf{p}'_{m2} \rangle}{\|h_{m1}\| \|h_{m2}\|}$$

$$\langle \mathbf{c} + \mathbf{p}'_{m1}, \mathbf{c} + \mathbf{p}'_{m2} \rangle = \langle \mathbf{c}, \mathbf{c} \rangle + \langle \mathbf{c}, \mathbf{p}'_{m1} \rangle + \langle \mathbf{c}, \mathbf{p}'_{m2} \rangle + \langle \mathbf{p}'_{m1}, \mathbf{p}'_{m2} \rangle$$

前提 → 類似度計算に固有表現はノイズ → InfoNCEは固有表現を抑制できない

3. ZS分類に特化した共通空間

h_{m1}, h_{m2} 間の類似度計算

$$h_{m1} = M_{m1}(c_{m1} + p_{m1}) = \mathbf{c} + \mathbf{p}'_{m1}$$

$$h_{m2} = M_{m2}(c_{m2} + p_{m2}) = \mathbf{c} + \mathbf{p}'_{m2}$$

h_{m1}, h_{m2} に対して、**類似度計算**を行う

$$\text{sim}(h_{m1}, h_{m2}) = \frac{\langle \mathbf{c} + \mathbf{p}'_{m1}, \mathbf{c} + \mathbf{p}'_{m2} \rangle}{\|h_{m1}\| \|h_{m2}\|}$$

$$\langle \mathbf{c} + \mathbf{p}'_{m1}, \mathbf{c} + \mathbf{p}'_{m2} \rangle = \langle \mathbf{c}, \mathbf{c} \rangle + \langle \mathbf{c}, \mathbf{p}'_{m1} \rangle + \langle \mathbf{c}, \mathbf{p}'_{m2} \rangle + \langle \mathbf{p}'_{m1}, \mathbf{p}'_{m2} \rangle$$

$\langle \mathbf{c}, \mathbf{c} \rangle$ 以外の項は異なる情報を有しており、

- ・ 正例であっても過小評価される
- ・ 負例であっても過大評価される

前提 → 類似度計算に固有表現はノイズ → InfoNCEは固有表現を抑制できない

3. ZS分類に特化した共通空間

$$\langle c+p'_{m1}, c+p'_{m2} \rangle = \langle c, c \rangle + \underbrace{\langle c, p'_{m1} \rangle + \langle c, p'_{m2} \rangle + \langle p'_{m1}, p'_{m2} \rangle}_{\text{類似度計算から排除}}$$

類似度計算から排除

→ 固有表現 p' はノイズと仮定し、類似度計算に必要な情報

||

共通表現のみ

前提 → 類似度計算に固有表現はノイズ → InfoNCEは固有表現を抑制できない

3. ZS分類に特化した共通空間

背理法

InfoNCEは固有表現を抑制する

前提 → 類似度計算に固有表現はノイズ → InfoNCEは固有表現を抑制できない

3. ZS分類に特化した共通空間

背理法

共通表現のみ < 固有表現混入なら、InfoNCEは固有表現を抑制する

前提 → 類似度計算に固有表現はノイズ → InfoNCEは固有表現を抑制できない

3. ZS分類に特化した共通空間

背理法

共通表現のみ < 固有表現混入なら、InfoNCEは固有表現を抑制する

共通表現のみのInfoNCE

正例類似度 : $\mathbf{s}_+ = \text{sim}(c^i, c^i)$

負例類似度 : $\mathbf{s}_j = \text{sim}(c^i, c^j) (i \neq j)$

前提 → 類似度計算に固有表現はノイズ → InfoNCEは固有表現を抑制できない

3. ZS分類に特化した共通空間

背理法

共通表現のみ < 固有表現混入なら、InfoNCEは固有表現を抑制する

共通表現のみのInfoNCE

正例類似度 : $\mathbf{s}_+ = \text{sim}(c^i, c^i)$

負例類似度 : $\mathbf{s}_j = \text{sim}(c^i, c^j) (i \neq j)$

$$\begin{aligned} L &= -\log \frac{\exp(s_+)}{\exp(s_+) + \sum_{j \neq i} \exp(s_j)} \\ &= \log(1 + \sum_{j \neq i} \exp(s_j - s_+)) \end{aligned}$$

前提 → 類似度計算に固有表現はノイズ → InfoNCEは固有表現を抑制できない

3. ZS分類に特化した共通空間

背理法

共通表現のみ < 固有表現混入なら、InfoNCEは固有表現を抑制する

共通表現のみのInfoNCE

正例類似度 : $\mathbf{s}_+ = \text{sim}(\mathbf{c}^i, \mathbf{c}^i)$

負例類似度 : $\mathbf{s}_j = \text{sim}(\mathbf{c}^i, \mathbf{c}^j) (i \neq j)$

$$L = -\log \frac{\exp(s_+)}{\exp(s_+) + \sum_{j \neq i} \exp(s_j)}$$
$$= \log(1 + \sum_{j \neq i} \exp(s_j - s_+))$$

固有表現が混入したInfoNCE

正例類似度 : $s'_+ = s_+ + \Delta_+$

負例類似度 : $s'_j = s_j + \Delta_j$

$$\Delta = \langle \mathbf{c}, \mathbf{p}'_{m1} \rangle + \langle \mathbf{c}, \mathbf{p}'_{m2} \rangle + \langle \mathbf{p}'_{m1}, \mathbf{p}'_{m2} \rangle$$

前提 → 類似度計算に固有表現はノイズ → InfoNCEは固有表現を抑制できない

3. ZS分類に特化した共通空間

背理法

共通表現のみ < 固有表現混入なら、InfoNCEは固有表現を抑制する

共通表現のみのInfoNCE

正例類似度 : $\mathbf{s}_+ = \text{sim}(\mathbf{c}^i, \mathbf{c}^i)$

負例類似度 : $\mathbf{s}_j = \text{sim}(\mathbf{c}^i, \mathbf{c}^j) (i \neq j)$

$$\begin{aligned} L &= -\log \frac{\exp(s_+)}{\exp(s_+) + \sum_{j \neq i} \exp(s_j)} \\ &= \log(1 + \sum_{j \neq i} \exp(s_j - s_+)) \end{aligned}$$

固有表現が混入したInfoNCE

正例類似度 : $s'_+ = s_+ + \Delta_+$

負例類似度 : $s'_j = s_j + \Delta_j$

$$\Delta = \langle \mathbf{c}, \mathbf{p}'_{m1} \rangle + \langle \mathbf{c}, \mathbf{p}'_{m2} \rangle + \langle \mathbf{p}'_{m1}, \mathbf{p}'_{m2} \rangle$$

$$\begin{aligned} L &= -\log \frac{\exp(s'_+)}{\exp(s'_+) + \sum_{j \neq i} \exp(s'_j)} \\ &= \log(1 + \sum_{j \neq i} (\exp(s_j - s_+) + \exp(s_j - s_+))) \end{aligned}$$

前提 → 類似度計算に固有表現はノイズ → InfoNCEは固有表現を抑制できない

3. ZS分類に特化した共通空間

具体的に共通表現のみ < 固有表現混入に数式を当てはめる

$$\log\left(1 + \sum_{j \neq i} \exp(s_j - s_+)\right) < \log\left(1 + \sum_{j \neq i} \exp((s_j - s_+) + \exp(\Delta_j - \Delta_+))\right)$$

前提 → 類似度計算に固有表現はノイズ → InfoNCEは固有表現を抑制できない

3. ZS分類に特化した共通空間

具体的に共通表現のみ < 固有表現混入に数式を当てはめる

$$\log\left(1 + \sum_{j \neq i} \exp(s_j - s_+)\right) < \log\left(1 + \sum_{j \neq i} \exp((s_j - s_+) + \exp(\Delta_j - \Delta_+))\right)$$

$$\sum_{j \neq i} \exp(s_j - s_+) < \sum_{j \neq i} \exp((s_j - s_+) + (\Delta_j - \Delta_+))$$

前提 → 類似度計算に固有表現はノイズ → InfoNCEは固有表現を抑制できない

3. ZS分類に特化した共通空間

具体的に共通表現のみ < 固有表現混入に数式を当てはめる

$$\log\left(1 + \sum_{j \neq i} \exp(s_j - s_+)\right) < \log\left(1 + \sum_{j \neq i} \exp((s_j - s_+) + \exp(\Delta_j - \Delta_+))\right)$$

$$\sum_{j \neq i} \exp(s_j - s_+) < \sum_{j \neq i} \exp((s_j - s_+) + (\Delta_j - \Delta_+))$$

InfoNCEが固有表現を抑制する条件： $\Delta_j - \Delta_+ > 0$

固有表現の混入した影響が常に正例よりも負例への方が大きい

前提 → 類似度計算に固有表現はノイズ → InfoNCEは固有表現を抑制できない

3. ZS分類に特化した共通空間

具体的に共通表現のみ < 固有表現混入に数式を当てはめる

$$\log\left(1 + \sum_{j \neq i} \exp(s_j - s_+)\right) < \log\left(1 + \sum_{j \neq i} \exp((s_j - s_+) + \exp(\Delta_j - \Delta_+))\right)$$

$$\sum_{j \neq i} \exp(s_j - s_+) < \sum_{j \neq i} \exp((s_j - s_+) + (\Delta_j - \Delta_+))$$

InfoNCEが固有表現を抑制する条件： $\Delta_j - \Delta_+ < 0$

固有表現の混入した影響が常に正例よりも負例への方が大きい

しかし、固有表現が正例・負例に与える影響度の分布は等しく、
常に条件式を満たさず、InfoNCEは一般的に固有表現を抑制できない

モデル構造 → 学習方法(4つの損失関数)

4. モデル構造と学習方法


研究目的：類似度計算を共通表現のみで行う → 共通表現のみの共通空間

モデル構造 → 学習方法(4つの損失関数)

4. モデル構造と学習方法

研究目的：類似度計算を共通表現のみで行う → **共通表現のみの共通空間**

シンプルなアイデアとして、




モデル構造 → 学習方法(4つの損失関数)

4. モデル構造と学習方法

研究目的：類似度計算を共通表現のみで行う → 共通表現のみの共通空間

シンプルなアイデアとして、




共通-固有分離 W_1 、軸整合 W_2 どちらも線形変換であるため、

$$W_2(W_1(z)) = (\mathbf{W}_2 \mathbf{W}_1)z = \mathbf{W}z$$

モデル構造 → 学習方法(4つの損失関数)

4. モデル構造と学習方法

研究目的：類似度計算を共通表現のみで行う → **共通表現のみの共通空間**




1つのモジュールが、

共通-固有分離 × 軸整合

モデル構造 → 学習方法(4つの損失関数)


4. モデル構造と学習方法



モデル構造は一般的な共通-固有分離と同じ（**線形変換2つ**×モダリティ数）

モデル構造 → 学習方法(4つの損失関数)


4. モデル構造と学習方法



L_{con} : InfoNCEを言語と音声に拡張したもの
しかし、InfoNCEは一般的に**固有表現を抑制しない** (3.2節で議論)

モデル構造 → 学習方法(4つの損失関数)

4. モデル構造と学習方法




L_{con} : InfoNCEを言語と音声に拡張したもの
しかし、InfoNCEは一般的に固有表現を抑制しない（3.2節で議論）

L_{sim} : 共通表現同士を明示的に揃え、固有成分を抑制するもの

モデル構造 → 学習方法(4つの損失関数)

4. モデル構造と学習方法



L_{diff} : 固有表現側に混入した共通成分を抑制するもの

L_{recon} : 共通表現と固有表現への分離による情報損失を抑制するもの

最終的な損失 : $\lambda_1 L_{con} + \lambda_2 L_{sim} + \lambda_3 L_{diff} + \lambda_4 L_{recon}$

実験設定 → Main実験 → 情報量ablation実験 → batch-size変更の影響

5. 実験・考察



- ・ 言語-音声間の共通空間学習

- ・ 学習用データ

FSD50K (51,197) + ClothoV2 (29,645) + AudioCaps (50,948) = 131,790

- ・ 評価用データ

5つのデータセット

ESC-50, UrbanSound8K, Beijing Opera, TUT2017, VocalSound

- ・ 実験設定

バッチサイズ=256, 80epoch, 学習率= $1e^{-3}$, シード={41,42,43}

実験設定 → Main実験 → 情報量ablation実験 → batch-size変更の影響

5. 実験・考察

共通表現のみを用いることで、ベースラインを一貫して上回る

	Sound Event		Instrument	Acoustic Scene	Vocal Sound
Dataset	ESC-50	US8K	Beijing Opera	TUT2017	Vocal Sound
Random	2.00	10.00	25.00	6.00	16.67
Baseline	39.63 ± 0.06	44.72 ± 0.14	35.31 ± 1.06	12.61 ± 0.51	31.04 ± 0.15
Our Method	40.17 ± 0.05	46.77 ± 0.15	36.02 ± 0.35	14.63 ± 0.46	31.56 ± 0.29

実験設定 → Main実験 → 情報量ablation実験 → batch-size変更の影響

5. 実験・考察

類似度計算において、共通表現同士以外の項はノイズとなる検証

	ESC-50
Random	2.00
$\langle c, c \rangle$ (Our Method)	40.17 ± 0.05
$\langle \mathbf{c}, \mathbf{p}'_{m1} \rangle$	2.07 ± 0.12
$\langle \mathbf{c}, \mathbf{p}'_{m2} \rangle$	2.38 ± 0.78
$\langle \mathbf{p}'_{m1}, \mathbf{p}'_{m2} \rangle$	1.95 ± 0.10

$$\langle c+p'_{m1}, c+p'_{m2} \rangle = \langle c, c \rangle + \langle \mathbf{c}, \mathbf{p}'_{m1} \rangle + \langle \mathbf{c}, \mathbf{p}'_{m2} \rangle + \langle \mathbf{p}'_{m1}, \mathbf{p}'_{m2} \rangle$$

$\langle c, c \rangle$ 以外の項はRandomと等しく、

実験設定 → Main実験 → 情報量ablation実験 → batch-size変更の影響

5. 実験・考察

類似度計算において、共通表現同士以外の項はノイズとなる検証

	ESC-50
Random	2.00
$\langle c, c \rangle$ (Our Method)	40.17 ± 0.05
$\langle \mathbf{c}, \mathbf{p}'_{m1} \rangle$	2.07 ± 0.12
$\langle \mathbf{c}, \mathbf{p}'_{m2} \rangle$	2.38 ± 0.78
$\langle \mathbf{p}'_{m1}, \mathbf{p}'_{m2} \rangle$	1.95 ± 0.10


$$\langle c + p'_{m1}, c + p'_{m2} \rangle = \langle c, c \rangle + \langle \mathbf{c}, \mathbf{p}'_{m1} \rangle + \langle \mathbf{c}, \mathbf{p}'_{m2} \rangle + \langle \mathbf{p}'_{m1}, \mathbf{p}'_{m2} \rangle$$

$\langle c, c \rangle$ 以外の項はRandomと等しく、
「固有表現が類似度計算において
ノイズとなる」理論仮説と整合する

実験設定 → Main実験 → 情報量ablation実験 → batch-size変更の影響

5. 実験・考察

すべてのbatch-sizeにおいて、ベースラインを上回る



6. 結論

本研究の貢献

1. ZS 分類において必要となる情報構造に着目し、固有表現がノイズとして働くことを理論的および実験的に示した。
2. 既存手法のみでは、固有表現を抑制出来ない事を議論（3.2節）
3. 軸整合を共通表現に対してのみ行う、共通空間学習を提案（4章）
4. 既存の共通空間学習手法を全ての下流データセットで上回った